

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



Báo cáo Đồ án

Khám phá dữ liệu sức khỏe tâm thần

Môn học: CSC170013 – Phân tích dữ liệu thông minh

Trình bày bởi nhóm 15:

22127059 - Huỳnh Tấn Đạt
22127202 - Võ Hùng Khoa
22127359 - Chu Thúy Quỳnh
22127404 - Tạ Minh Thư
22127361 - Nguyễn Hoàng Sang

Giáo viên hướng dẫn:

GV. Nguyễn Tiến Huy
GV. Nguyễn Thanh Tình
GV. Lê Thanh Tùng

TP. Hồ Chí Minh, ngày 24 tháng 11 năm 2025

Mục lục

I. Giới thiệu	2
II. Đánh giá mức độ hoàn thành	2
III. Nội dung báo cáo	3
1. Tổng quan dự án	3
2. Khám phá dữ liệu	3
2.1 Mô tả dataset	3
2.2 Các biến chính	3
2.3 Xử lý dữ liệu thiếu	4
2.4 Phân tích phân phối Depression	6
2.5 CGPA	7
2.6 Age	8
2.7 Work/Study Hours	9
2.8 Gender, Suicidal Thoughts, Family History	10
2.9 Financial Stress, Work/Academic Pressure, Job/Study Satisfaction	11
2.10 Dietary Habits	12
2.11 Sleep Duration	13
2.12 Phân tích Ma trận tương quan	14
3. Tiền xử lý dữ liệu	16
3.1 Mã hóa dữ liệu	16
3.2 Xử lý dữ liệu thiếu	16
4. Feature Engineering	17
5. Mô hình	17
5.1 Pipeline xử lý dữ liệu	17
5.2 Base models	17
5.3 Quy trình train model base	20
5.4 Pseudo-Labeling	20
5.5 Stacking	20
6. Thử nghiệm và kết quả	21
6.1 Thiết lập thí nghiệm	21
6.2 Các tiêu chí đánh giá	21
6.3 Kết quả huấn luyện và đánh giá mô hình	22
6.4 Phân tích chi tiết.	23
6.5 Kết quả nộp trên Kaggle	23
7. Kết luận và cải tiến	24
7.1 Kết luận	24
7.2 Cải tiến	24
7.3 Video thuyết trình	24
Nguồn tham khảo	25

I. Giới thiệu

Thông tin sinh viên

MSSV	Họ Tên	Ghi chú
22127202	Võ Hùng Khoa	Thành Viên
22127059	Huỳnh Tấn Đạt	Thành Viên
22127459	Chu Thúy Quỳnh	Thành Viên
22127404	Tạ Minh Thư	Thành Viên
22127361	Nguyễn Hoàng Sang	Thành Viên

II. Đánh giá mức độ hoàn thành

Mức độ hoàn thành tổng thể của mỗi yêu cầu

Yêu cầu	Mô tả	Mức độ hoàn thành
Source Code	Bao gồm 2 file notebook: EDA và Modeling	100%
Report	Bao gồm đầy đủ các thành phần được liệt kê trong yêu cầu	100%
Video	Video thuyết trình quá trình và báo cáo kết quả	100%

Table 1: Mức độ hoàn thành các yêu cầu đồ án

Mức độ hoàn thành của từng thành viên

Tên thành viên	Nhiệm vụ	Mức độ hoàn thành
Võ Hùng Khoa	Phân chia công việc và viết báo cáo	100%
Huỳnh Tấn Đạt	Khám phá và xử lý dữ liệu	100%
Chu Thúy Quỳnh	Xây dựng mô hình và đánh giá kết quả	100%
Tạ Minh Thư	Phân tích và đánh giá kết quả	100%
Nguyễn Hoàng Sang	Soạn script thuyết trình và làm video	100%

Table 2: Mức độ hoàn thành của các thành viên

III. Nội dung báo cáo

1. Tổng quan dự án

Dự án “Exploring Mental Health Data” được thực hiện dựa trên cuộc thi Kaggle cùng tên, với mục tiêu xây dựng mô hình Machine Learning dự đoán khả năng một cá nhân có dấu hiệu trầm cảm hay không dựa trên dữ liệu khảo sát sức khỏe tinh thần. Đây là bài toán phân loại nhị phân với biến mục tiêu Depression.

Nhóm tiến hành tải dữ liệu từ Kaggle, phân tích và làm sạch dữ liệu, thử nghiệm nhiều mô hình khác nhau và gửi kết quả dự đoán lên bảng xếp hạng Kaggle để đánh giá hiệu quả mô hình theo yêu cầu của đề bài. Đồng thời, nhóm thực hiện đầy đủ các phần báo cáo và trình bày theo đúng hướng dẫn của môn học.

2. Khám phá dữ liệu

2.1 Mô tả dataset

Tập dữ liệu bao gồm các thông tin khảo sát sức khỏe tinh thần của các cá nhân và được tạo tổng hợp từ một mô hình học sâu dựa trên bộ dữ liệu khảo sát (Depression Survey/Dataset for Analysis). Do đó, phân phối các đặt trưng của dữ liệu này có phần tương đồng với dữ liệu thật.

Về mặt tổng quan, dữ liệu bao gồm 2 tập dữ liệu: train và test. Cụ thể:

- Tập dữ liệu train:
 - 140,700 bản ghi
 - 20 cột thuộc tính
- Tập dữ liệu test:
 - 93,800 bản ghi
 - 19 cột thuộc tính

2.2 Các biến chính

Tổng quan tập dữ liệu bao gồm các biến chính sau:

- Depression: (0 = Không trầm cảm, 1 = Trầm cảm)
- Age: Tuổi
- Gender: Giới tính (Male/Female)
- CGPA: Điểm trung bình tích lũy
- Academic Pressure: Mức độ áp lực học tập (1-5)
- Work Pressure: Mức độ áp lực công việc (1-5)
- Study Satisfaction: Mức độ hài lòng với việc học (1-5)
- Job Satisfaction: Mức độ hài lòng với công việc (1-5)
- Financial Stress: Mức độ căng thẳng tài chính (1-5)
- Work/Study Hours: Số giờ làm việc hoặc học mỗi ngày
- Sleep Duration: Thời lượng ngủ
- Dietary Habits: Thói quen ăn uống
- Have you ever had suicidal thoughts?: Có từng có ý nghĩ tự sát hay không (Yes/No)
- Family History of Mental Illness: Tiền sử gia đình bệnh tâm thần (Yes / No)

2.3 Xử lý dữ liệu thiếu




Figure 1: Biểu đồ tỷ lệ phần trăm giá trị thiếu trong dữ liệu.

Phân tích ban đầu cho thấy một số biến có tỷ lệ giá trị thiếu cao:

- Academic Pressure, Study Satisfaction, CGPA: ($\approx 80\%$)
- Profession, Work Pressure, Job Satisfaction: ($\approx 20-26\%$)

Dữ liệu thiếu xuất hiện do cấu trúc dataset: **Các biến học tập chỉ áp dụng cho Student** và **các biến công việc chỉ áp dụng cho Working Professional**.

→ **Giải pháp:** Thay vì điền giá trị thiếu, dataset được tách thành hai nhóm riêng biệt dựa trên biến **Working Professional or Student**. Mỗi nhóm sau đó loại bỏ các biến không áp dụng.




Figure 2: Biểu đồ tỷ lệ phần trăm giá trị thiếu của Working Professional.





Figure 3: Biểu đồ tỷ lệ phần trăm giá trị thiếu của Student.

Kết quả sau xử lý:

- **Working Professional:** 112,799 người (loại bỏ: Academic Pressure, Study Satisfaction, CGPA).
- **Student:** 27,901 người (loại bỏ: Work Pressure, Job Satisfaction, Profession).

2.4 Phân tích phân phối Depression

Phân phối Depression của Working Professional



Phân phối Depression của Student




Figure 4: Biểu đồ phân phối Depression.

- **Tổng quan:**

Có sự khác biệt rõ rệt về tỷ lệ Depression giữa hai nhóm:

- Working Professional: Có số lượng đông hơn và chỉ 8.2% bị trầm cảm.
- Student: 41.5% có triệu chứng trầm cảm.
- Chênh lệch: Student cao hơn gấp **≈5 lần**.

- **Nhận xét:**

- Phần lớn Working Professional (>90%) duy trì sức khỏe tâm lý ổn định.
- Student là nhóm có nguy cơ trầm cảm cao.

→ **Kết luận:** Biểu đồ cho thấy tỷ lệ trầm cảm giữa Student và Working Professional khác biệt rõ rệt, gợi ý rằng các biến trong dataset có thể tác động khác nhau lên từng nhóm. Do đó, ta cần trực quan hóa để tìm hiểu các biến ảnh hưởng như thế nào đến tỷ lệ trầm cảm.

2.5 CGPA




Figure 5: Biểu đồ phân phối CGPA của Student.




Figure 6: Biểu đồ tỷ lệ Depression theo CGPA của Student.

- **Đặc điểm phân phối:** Có hình dạng lượn sóng với nhiều đỉnh nhỏ → thực lực học của Student phân bố khá đều.
- **Mối quan hệ với Depression:**
 - Mức nền tỷ lệ trầm cảm rất cao: Ở bất kỳ mức điểm nào, tỷ lệ sinh viên mắc trầm cảm đều trên 55%.
 - CGPA 9.0-10.0: 56-59% trầm cảm.
 - CGPA 5.0-6.0: 55-56% trầm cảm.
 - CGPA 8.0-9.0: tỷ lệ cao nhất ($\approx 64\%$).

→ **Kết luận:** CGPA không phải là yếu tố dự báo có ý nghĩa cho Depression. Student thành tích cao và thấp có tỷ lệ trầm cảm tương đương nhau.

2.6 Age




Figure 7: Biểu đồ phân phối Age và tỷ lệ Depression.

• Working Professional:

– Phân phối:

- * Đa số trong độ tuổi 40-55.
- * Biểu đồ phình to ở đoạn giữa và cuối, cho thấy đa số người đi làm trong dữ liệu này là những người đã có kinh nghiệm hoặc lớn tuổi. Nhóm trẻ hơn (dưới 32) chiếm tỷ trọng nhỏ hơn.

– Xu hướng trầm cảm:

- * Nhóm 18-30 tuổi: Có phân bố thấp nhất nhưng tỷ lệ trầm cảm cao nhất, đạt đỉnh gần 60% ở nhóm trẻ nhất.
- * Giảm mạnh theo tuổi: gần như 0% sau 40 tuổi.

• Student:

– Phân phối:

- * Tập trung ở 20-28 tuổi.
- * Biểu đồ phình to nhất ở đoạn đầu và thụt lại rất nhanh sau tuổi 30. Có đuôi dài kéo đến 60 tuổi, nhưng rất mỏng, cho thấy sinh viên lớn tuổi là rất hiếm.

– Xu hướng trầm cảm:

- * Phổ biến ở nhóm trẻ, cao nhất 71.2% trong độ tuổi 18-22.
- * Giảm dần nhưng vẫn cao hơn Working Professional cùng độ tuổi.
- * Nhóm 51-60 tuổi: 100% không trầm cảm, nhưng do số lượng mẫu ở độ tuổi này quá ít, con số này có thể không mang ý nghĩa thống kê lớn.

• So sánh:

- Student có tỷ lệ trầm cảm cao hơn ở nhóm tuổi 18 → 50.
- Việc làm có mối liên hệ với sức khỏe tâm lý tốt hơn sau độ tuổi trưởng thành.
- **Nhóm dễ bị trầm cảm nhất:** 18-26 tuổi trong cả hai nhóm.

→ **Kết luận:** Ở nhóm Working Professional, việc già đi giúp giảm thiểu trầm cảm đáng kể (giảm xuống dưới 10% sau tuổi 30). Với nhóm Student, việc lớn tuổi hơn không giúp ích nhiều, một sinh viên 40 tuổi vẫn có tỷ lệ trầm cảm cao (41%)

2.7 Work/Study Hours




Figure 8: Biểu đồ phân phối Work/Study Hour và tỷ lệ Depression.

• Working Professional:

- Phân phối: Phân bố khá đều ở các mốc giờ, nhưng tập trung đông đảo ở mức cường độ cao (9-11 giờ). Nhóm làm việc 0 giờ cũng chiếm số lượng lớn.
- Xu hướng trầm cảm:
 - * Thấp và ổn định: dưới 10% từ 0-9 giờ.
 - * Chỉ khi làm việc từ 10-12 giờ, tỷ lệ trầm cảm mới tăng nhẹ ($\approx 15-18\%$).

• Student:

- Phân phối: Số lượng sinh viên phân bố rải rác, nhưng có xu hướng tăng dần ở các mốc thời gian cao.
- Xu hướng trầm cảm:
 - * Vì có tỷ lệ nền cao, nhóm 0 giờ có tỷ lệ trầm cảm thấp nhất vẫn đạt gần 40%.
 - * Nhóm 10 giờ: Có phân bố lớn nhất và tỷ lệ trầm cảm cao nhất ($\approx 70\%$), cao hơn gấp ≈ 3.5 lần Working Professional cùng số giờ.

• So sánh:

- Student có tỷ lệ trầm cảm cao hơn ở **mọi mức số giờ**. Tỷ lệ trầm cảm của nhóm Student có 0 giờ học cao gấp **2 lần** so với Working Professional làm việc 12 giờ.
- Working Professional và Student có chung xu hướng: **Số giờ làm việc/học tập tăng $\rightarrow$ Tỷ lệ trầm cảm tăng**. Tuy nhiên, cả hai nhóm đều có tỷ lệ trầm cảm giảm tại *9 giờ* và *11 giờ*.
- Biên độ thay đổi: Student dao động cao hơn $\approx 40-70\%$, Working Professional chỉ $\approx 3-20\%$.

$\rightarrow$ **Kết luận:** Số giờ làm việc/học tập tăng có xu hướng dẫn đến tỷ lệ trầm cảm tăng. Tỷ lệ Depression của Student tăng mạnh hơn so với Working Professional.

2.8 Gender, Suicidal Thoughts, Family History




Figure 9: Biểu đồ phân phối Gender, Suicidal Thoughts, Family History - Student.

• Working Professional:

- **Gender:** "Male" chiếm số lượng nhiều hơn, tỷ lệ trầm cảm thấp và tương đương ở cả hai giới.
- **Suicidal thoughts:**
 - * Nhóm "No": Có số lượng cao hơn, tỷ lệ thấp ($\approx 5\%$).
 - * Nhóm "Yes": Tỷ lệ trầm cảm cao hơn đáng kể ($\approx 20\%$).
 - * Đáng chú ý: Nhiều người trả lời "Yes" nhưng chỉ $\approx 20\%$ được phân loại có trầm cảm.
- **Family History of Mental Illness:** Tỷ lệ trầm cảm thấp, phân bố và tỷ lệ trầm cảm không có khác biệt nhiều ở cả "No" và "Yes".

• Student:

- **Gender:** "Male" đông hơn, cả hai giới tính đều có tỷ lệ trầm cảm rất cao ($\approx 60\%$).
- **Suicidal thoughts:**
 - * Nhóm "Yes": Có phân bố đông hơn và tỷ lệ trầm cảm cao ($\approx 80\%$) - **yếu tố phân biệt mạnh nhất**.
 - * Nhóm "No": Tỷ lệ vẫn cao ($\approx 25\%$) do tỷ lệ nền chung cao.
- **Family History of Mental Illness:** Tỷ lệ trầm cảm của cả hai nhóm đều cao, nhóm "Yes" cao hơn một chút ($\approx 62\%$ vs $\approx 57\%$).

• So sánh:

- **Gender và Family History:** Có phân bố tương tự nhau và đều không phải yếu tố phân biệt mạnh ở cả hai nhóm Working Professional và Student.
- Student có tỷ lệ trầm cảm cao hơn ở **mọi phân nhóm** - ngay cả nhóm có tỷ lệ thấp nhất của Student vẫn vượt nhóm tỷ lệ cao nhất của Working Professional.

→ **Kết luận: Suicidal Thoughts** là chỉ số quan trọng nhất với cả hai nhóm, đặc biệt Student có tỷ lệ trầm cảm cao hơn nhiều so với Working Professional (80% vs 20%).

2.9 Financial Stress, Work/Academic Pressure, Job/Study Satisfaction




Figure 10: Biểu đồ phân phối Financial Stress, Work/Academic Pressure, Job/Study Satisfaction.

• Working Professional:

- **Financial Stress:** Tương quan dương - mức căng thẳng cao hơn gắn với tỷ lệ trầm cảm cao hơn.
- **Work Pressure:** Tỷ lệ trầm cảm tăng theo mức áp lực công việc.
- **Job Satisfaction:** Tương quan nghịch - mức độ hài lòng cao giúp giảm nguy cơ trầm cảm.

• Student:

- **Financial Stress:** Tỷ lệ trầm cảm có xu hướng tăng mạnh, cao nhất đến hơn 80% - tác động lớn hơn so với Working Professional.
- **Academic Pressure:** Tỷ lệ trầm cảm tăng rõ nét, mức áp lực cao đẩy tỷ lệ trầm cảm lên đáng kể. Tỷ lệ trầm cảm cao nhất lên đến gần 90%.
- **Study Satisfaction:** Độ hài lòng cao có giảm trầm cảm nhưng tỷ lệ nền vẫn cao ở mọi mức.

• So sánh:

- Dữ liệu phân phối khá đồng đều ở các mức độ stress/pressure/satisfaction khác nhau.
- Student có tỷ lệ trầm cảm cao hơn ở **mọi mức độ** stress/pressure/satisfaction.
- Student nhạy cảm với stress/pressure hơn - thay đổi mức áp lực và tài chính tạo biên độ dao động lớn hơn.
- Working Professional thay đổi nhẹ hơn nhưng vẫn chịu tác động rõ từ Work Pressure và Financial Stress.

→ **Kết luận:** Mọi yếu tố stress/pressure đều tác động đến tỷ lệ trầm cảm mạnh hơn lên Student so với Working Professional.

2.10 Dietary Habits




Figure 11: Biểu đồ phân phối Dietary Habits và tỷ lệ Depression.

- **Working Professional:**

- Tỷ lệ trầm cảm giảm dần khi chất lượng dinh dưỡng cải thiện.
 - * Unhealthy: $\approx 15\%$.
 - * Moderate: $\approx 8\%$.
 - * Healthy: $\approx 5\%$.

- **Student:**

- Nhóm Unhealthy chiếm số lượng Student lớn nhất.
- Tỷ lệ trầm cảm cao ở mọi nhóm (45-70%):
 - * Unhealthy: Cao nhất ($\approx 70\%$).
 - * Healthy: Thấp nhất nhưng vẫn cao hơn nhiều so với Working Professional ($\approx 45\%$).

- **So sánh:**

- Dữ liệu phân bố tương đối đều giữa ba nhóm (Unhealthy, Moderate, Healthy).
- Cả hai nhóm Working Professional và Student đều thể hiện xu hướng: **Dinh dưỡng kém $\rightarrow$ Trầm cảm cao hơn.**
- Tỷ lệ trầm cảm của Student giảm mạnh hơn so với Working Professional.

$\rightarrow$ **Kết luận:** Dinh dưỡng có tác động mạnh hơn đến Student so với Working Professional.

2.11 Sleep Duration




Figure 12: Biểu đồ phân phối Sleep Duration và tỷ lệ Depression.

- **Working Professional:**

- Tỷ lệ trầm cảm rất thấp ở mọi nhóm thời lượng ngủ (dưới 15%).
- Ít biến động giữa các nhóm ngủ khác nhau.

- **Student:**

- Tỷ lệ trầm cảm cao ở mọi mức (50-65%), vượt xa Working Professional.
- Xu hướng: Giảm nhẹ khi ngủ nhiều hơn:
 - * 4 giờ: Cao nhất ($\approx 65\%$).
 - * 9 giờ: Thấp nhất ($\approx 50\%$).

- **So sánh:**

- Phần lớn cả hai nhóm ngủ 4 giờ hoặc 7-8 giờ.
- Khoảng cách giữa hai nhóm rất lớn: ngay cả Student ngủ đủ giấc (9 giờ) vẫn có tỷ lệ trầm cảm cao hơn gấp **5 lần** Working Professional thiếu ngủ nhất.

→ **Kết luận:** Ngủ đủ giấc giúp giảm nguy cơ trầm cảm nhưng có tác động khá nhỏ.

2.12 Phân tích Ma trận tương quan




Figure 13: Ma trận tương quan của Working Professional.

• Working Professional:

- Age (-0.47): Yếu tố dự báo mạnh nhất - tuổi cao hơn gắn với nguy cơ trầm cảm thấp hơn đáng kể.
- Suicidal Thoughts (0.25) và Work Pressure (0.22): Tương quan dương mức trung bình.
- Financial Stress (0.19), Job Satisfaction (-0.17), Dietary Habits (-0.12), Work Hours (0.14): Tương quan yếu, có ít ảnh hưởng đến tỷ lệ trầm cảm.




Figure 14: Ma trận tương quan của Student.

• **Student:**

- Suicidal Thoughts (0.55): Yếu tố dự báo mạnh nhất, Student có suy nghĩ tự tử có xu hướng bị trầm cảm.
- Academic Pressure (0.48) và Financial Stress (0.36): Tương quan dương khá mạnh, là yếu tố quan trọng.
- Age (-0.23), Dietary Habits (-0.21), Study Hours (0.21): Tương quan mức trung bình
- Study Satisfaction (-0.17): Tác động yếu.
- CGPA (0.05): Gần như không có mối liên hệ.

• **So sánh:**

- Suicidal Thoughts, Financial Stress và Pressure: Có tác động gấp đôi ở Student (0.55 vs 0.25, 0.36 vs 0.19, 0.48 vs 0.22).
- Dietary Habits: Ảnh hưởng mạnh hơn ở Student (-0.21 vs -0.12) so với Working Professional.
- Gender, Sleep Duration, Family History: Tương quan yếu ở cả hai nhóm.

3. Tiền xử lý dữ liệu

3.1 Mã hóa dữ liệu

Để chuẩn bị dữ liệu cho các mô hình máy học, các biến phân loại (categorical) và biến thứ bậc (ordinal) sẽ được chuyển đổi sang dạng số. Quy trình này đã được áp dụng cho tập dữ liệu của *Working Professional* và *Student* ở phần trực quan hóa phía trên và giờ sẽ được áp dụng cho tập **Train** và **Test**.

- **Biến nhị phân (Binary Variables)** Các biến có hai giá trị được mã hóa về dạng 0 và 1:
 - **Gender:** Female $\rightarrow$ 0, Male $\rightarrow$ 1.
 - **Working Professional or Student:** Student $\rightarrow$ 0, Working Professional $\rightarrow$ 1.
 - **Have you ever had suicidal thoughts?:** No $\rightarrow$ 0, Yes $\rightarrow$ 1.
 - **Family History of Mental Illness:** No $\rightarrow$ 0, Yes $\rightarrow$ 1.
- **Biến thứ bậc (Ordinal Variables)** Các biến có tính chất xếp hạng hoặc khoảng giá trị được chuyển đổi sang các giá trị số, các giá trị này được chọn dựa trên các giá trị phổ biến nhất trong từng cột.
 - **Sleep Duration:** Các khoảng thời gian được chuyển đổi thành giá trị trung bình đại diện.
 - * Less than 5 hours $\rightarrow$ 4.0
 - * 5-6 hours $\rightarrow$ 5.5
 - * 7-8 hours $\rightarrow$ 7.5
 - * More than 8 hours $\rightarrow$ 9.0
 - **Dietary Habits:** Chuyển đổi theo mức độ lành mạnh tăng dần.
 - * Unhealthy $\rightarrow$ 0
 - * Moderate $\rightarrow$ 1
 - * Healthy $\rightarrow$ 2

3.2 Xử lý dữ liệu thiếu

Dữ liệu thiếu được xử lý theo ba chiến lược chính: gán có điều kiện, gán bằng tham số thống kê và gán nhãn "missing".

- **Gán giá trị dựa trên điều kiện tìm hiểu được trong dữ liệu:** Do đặc thù của đối tượng khảo sát, một số trường thông tin không áp dụng cho nhóm đối tượng còn lại. Các trường hợp này được gán giá trị 0 (đại diện cho mức thấp nhất hoặc không áp dụng):
 - **Study Satisfaction và Academic Pressure:** Nếu là *Working Professional* $\rightarrow$ Gán 0 (vì họ không đi học).
 - **Job Satisfaction và Work Pressure:** Nếu là *Student* $\rightarrow$ Gán 0 (vì họ không đi làm).
- **Gán giá trị bằng tham số thống kê:** Đối với các giá trị số bị thiếu còn lại, phương pháp điền dữ liệu được áp dụng như sau:
 - **Biến định lượng:** *Age, CGPA, Work/Study Hours*
 - * **Phương pháp:** Sử dụng **Median**.
 - * **Lý do:** Trung vị ít bị ảnh hưởng bởi các outliers hơn so với trung bình (mean), giúp dữ liệu ổn định hơn.
 - **Biến phân loại:** *Academic Pressure, Work Pressure, Study Satisfaction, Job Satisfaction, Sleep Duration, Dietary Habits, Financial Stress*
 - * **Phương pháp:** Sử dụng **Mode** - giá trị xuất hiện nhiều nhất.
 - * **Lý do:** Đảm bảo giá trị được điền là giá trị phổ biến nhất trong tập dữ liệu.
- **Xử lý các biến định danh còn lại:** Đối với các cột dạng chuỗi còn lại chưa được xử lý ở trên (ví dụ: *Profession, Degree, City...*), các giá trị thiếu được điền bằng nhãn "**missing**".
 - **Mục đích:** Giữ lại thông tin về việc thiếu dữ liệu như một nhóm riêng biệt thay vì gán sai một nghề nghiệp hay thành phố cụ thể.

4. Feature Engineering

Nhóm không bổ sung hay loại bỏ bất kỳ đặc trưng nào vì trong quá trình thử nghiệm, mô hình cho thấy hiệu suất tốt nhất khi giữ nguyên toàn bộ tập feature ban đầu.

5. Mô hình

5.1 Pipeline xử lý dữ liệu

Trong quy trình tiền xử lý, có bốn loại pipeline được xác định thông qua tên như sau:

- p1 / p3: Chỉ thực hiện chuẩn hóa kiểu dữ liệu - chuyển các cột thuộc kiểu object sang category và đồng bộ các categories giữa các tập train, test và original.
- p2 / p4 Áp dụng tiền xử lý dữ liệu.
- p3 / p4: Về mặt xử lý, p3 tương ứng với p1 và p4 tương ứng với p2 - tuy nhiên hai pipeline này mở rộng dữ liệu huấn luyện bằng cách kết hợp pseudo-data. Pseudo-data được sinh từ dự đoán trên tập test của một mô hình “thầy” và được ghép vào tập huấn luyện để tạo dữ liệu mở rộng cho huấn luyện lại.

5.2 Base models

Sử dụng Optuna để thực hiện tối ưu siêu tham số cho các mô hình cơ sở: XGBoost Classifier, LightGBM GBDT Classifier, CatBoost Classifier, Logistic Regression, LightGBM GOSS Classifier, LightGBM DART Classifier

XGBoost Classifier (xgb) XGBoost là mô hình Gradient Boosting sử dụng cây quyết định, tối ưu mạnh về tốc độ và độ chính xác.

Tham số:

XGBoost Parameters

```
1 {
2   "max_bins": 26161,
3   "colsample_bylevel": 0.25155109886677396,
4   "colsample_bynode": 0.5723191165109757,
5   "colsample_bytree": 0.18034301813835885,
6   "enable_categorical": true,
7   "gamma": 3.6392698070258622,
8   "max_depth": 16,
9   "max_leaves": 67,
10  "min_child_weight": 34,
11  "n_estimators": 3853,
12  "n_jobs": -1,
13  "reg_alpha": 7.996080341061729,
14  "reg_lambda": 46.83054555763492,
15  "scale_pos_weight": 1.2157646356820928,
16  "subsample": 0.9117754083869292,
17  "random_state": 42,
18  "verbosity": 0
19 }
```

LightGBM GBDT (lgbm) LightGBM GBDT là mô hình boosting nhanh và hiệu quả, sử dụng kỹ thuật histogram giúp tối ưu hóa tốc độ, Phù hợp cho dữ liệu lớn.

Tham số:

LightGBM GBDT Parameters

```

1 {
2   "boosting_type": "gbdt",
3   "max_bins": 36644,
4   "colsample_bytree": 0.18283018243382332,
5   "learning_rate": 0.09945326391012832,
6   "min_child_samples": 105,
7   "min_child_weight": 0.2083765599710974,
8   "n_estimators": 244,
9   "n_jobs": -1,
10  "num_leaves": 122,
11  "reg_alpha": 8.662578235164972,
12  "reg_lambda": 3.5696291074963926,
13  "scale_pos_weight": 1.0733293968870794,
14  "subsample": 0.5360642841695424,
15  "random_state": 42,
16  "verbose": -1
17 }

```

CatBoost Classifier (cb) CatBoost là mô hình boosting được thiết kế đặc biệt để xử lý dữ liệu dạng categorical nhờ cơ chế mã hoá theo thứ tự (ordered target encoding), giúp giảm overfitting và hạn chế leakage.

Tham số:

CatBoost Parameters

```

1 {
2   "border_count": 180,
3   "depth": 4,
4   "iterations": 2372,
5   "l2_leaf_reg": 4.442847441200204,
6   "learning_rate": 0.0514109059943355,
7   "min_child_samples": 146,
8   "random_strength": 0.18678416655567043,
9   "scale_pos_weight": 1.019889465491297,
10  "subsample": 0.3511896501762123,
11  "bootstrap_type": "Bernoulli",
12  "verbose": false,
13  "random_state": 42
14 }

```

Logistic Regression + OneHotEncoder (lr) Đây là mô hình tuyến tính đơn giản nhưng quan trọng trong hệ thống ensemble. Logistic Regression kết hợp OneHotEncoder giúp mô hình xử lý categorical rõ ràng và cung cấp góc nhìn tuyến tính bổ trợ cho các mô hình phi tuyến.

Tham số:

Logistic Regression Parameters

```

1 {
2   "C": 5.559884346567435,
3   "max_iter": 1000,
4   "n_jobs": 4,
5   "penalty": "l2",
6   "solver": "newton-cg",
7   "tol": 0.08313081991676836,
8   "random_state": 42
9 }

```

OneHotEncoder:

OneHotEncoder

```
1 OneHotEncoder(handle_unknown='ignore', min_frequency=0.001)
```

LightGBM GOSS (goss) GOSS (Gradient-based One-Side Sampling) tập trung vào các mẫu có gradient lớn, giúp tăng hiệu quả học và tạo sự đa dạng cho bộ mô hình.

Tham số:

LightGBM GOSS Parameters

```
1 {
2   "boosting_type": "goss",
3   "max_bins": 18501,
4   "colsample_bytree": 0.11905309670044416,
5   "learning_rate": 0.04641567005485582,
6   "min_child_samples": 283,
7   "min_child_weight": 0.5242575557671028,
8   "n_estimators": 966,
9   "n_jobs": -1,
10  "num_leaves": 159,
11  "reg_alpha": 8.160196501794122,
12  "reg_lambda": 9.861767101758469,
13  "scale_pos_weight": 0.991416082619142,
14  "subsample": 0.9259030065865966,
15  "random_state": 42,
16  "verbose": -1
17 }
```

LightGBM DART (dart) DART sử dụng cơ chế dropout khi xây dựng cây, tương tự dropout trong mạng nơ-ron, giúp tránh overfitting và tăng khả năng tổng quát hóa.

Tham số:

LightGBM DART Parameters

```
1 {
2   "boosting_type": "dart",
3   "max_bins": 7386,
4   "colsample_bytree": 0.1181378019860333,
5   "reg_alpha": 2.9686583338116925,
6   "learning_rate": 0.0910272033595692,
7   "min_child_samples": 225,
8   "n_estimators": 1454,
9   "n_jobs": -1,
10  "num_leaves": 163,
11  "reg_lambda": 9.781841345026509,
12  "scale_pos_weight": 0.8309734952725212,
13  "min_child_weight": 0.28492487885169293,
14  "subsample": 0.511061530253864,
15  "random_state": 42,
16  "verbose": -1
17 }
```

AutoGluon AutoGluon là hệ thống AutoML tự động huấn luyện và tối ưu nhiều mô hình khác nhau. Hệ thống tự động thực hiện bagging, chọn mô hình tốt nhất và kết hợp chúng thông qua weighted ensemble. Nhờ đó, AutoGluon có khả năng đạt hiệu suất cao mà không cần tinh chỉnh thủ công. **Tham số:**

AutoGluon Parameters

```

1 {
2   "num_bag_folds": 5,
3   "num_bag_sets": 1,
4   "num_stack_levels": 0,
5   "fit_weighted_ensemble": true,
6   "eval_metric": "accuracy",
7   "presets": "high_quality",
8   "time_limit": 1800
9 }

```

5.3 Quy trình train model base

Trong quá trình huấn luyện các mô hình base, dữ liệu được xử lý qua hai pipeline: p1 (chỉ chuẩn hoá kiểu dữ liệu) và p2 (bao gồm cả ánh xạ và xử lý các giá trị thiếu). Hai pipeline này cho phép đánh giá mức độ ảnh hưởng của tiền xử lý và tăng sự đa dạng của các mô hình. Tuy nhiên, CatBoost không được huấn luyện với p1 do pipeline này không xử lý NaN, trong khi CatBoost yêu cầu dữ liệu đầu vào phải hoàn chỉnh.

Các mô hình base được huấn luyện theo chiến lược cross-validation nhằm đánh giá khách quan hiệu suất và tạo ra bộ dự đoán OOF phục vụ cho các bước stacking phía sau. Ở mỗi lần huấn luyện, dữ liệu được chia theo Stratified K-Fold để đảm bảo tỷ lệ lớp đồng đều giữa các fold. Với mỗi fold, mô hình được khởi tạo mới hoàn toàn để tránh ảnh hưởng từ các lần huấn luyện trước đó. Tập train và validation của fold hiện tại được tách riêng, sau đó mô hình được huấn luyện trên phần train và đánh giá trên phần validation.

Đối với từng loại mô hình, việc xử lý dữ liệu được điều chỉnh phù hợp: CatBoost sử dụng trực tiếp các cột dạng categorical, LightGBM nhận danh sách các biến category, trong khi XGBoost yêu cầu mã hóa các biến này thành dạng số nguyên trước khi huấn luyện. Trong mỗi fold, mô hình được huấn luyện kèm early stopping nhằm tránh overfitting và tối ưu thời gian.

Sau khi mô hình hoàn thành quá trình huấn luyện trên fold đó, dự đoán xác suất của tập validation được ghi lại vào vị trí tương ứng trong mảng OOF. Đồng thời, mô hình cũng dự đoán trên tập test và các dự đoán từ từng fold được trung bình hoá để tạo ra kết quả test cuối cùng. Quá trình này được lặp lại cho tất cả các fold và cho từng mô hình base, đảm bảo rằng kết quả OOF là dự đoán thật sự “ngoài fold”, phản ánh chính xác hiệu suất mô hình trên dữ liệu chưa từng thấy.

Cuối cùng, các giá trị OOF được dùng để tính điểm tổng thể của mô hình trên toàn bộ tập train, đồng thời lưu lại toàn bộ dự đoán test tương ứng. Nhờ quy trình này, mỗi mô hình base được đánh giá một cách minh bạch, độc lập và cung cấp đầu vào đáng tin cậy cho các bước ensemble tiếp theo.

5.4 Pseudo-Labeling

Trong giai đoạn pseudo-labeling, hệ thống trước hết xác định mô hình “thầy” bằng cách chọn mô hình base có điểm OOF cao nhất. Mô hình này được xem là đáng tin cậy nhất và được sử dụng để sinh nhãn giả cho tập test. Dựa trên các dự đoán xác suất của mô hình thầy, hệ thống tìm ngưỡng phân loại tối ưu từ chính OOF của mô hình này, bảo đảm rằng việc chuyển đổi xác suất thành nhãn nhị phân là nhất quán và hợp lý. Các dự đoán trên tập test sau khi được áp dụng ngưỡng sẽ tạo thành bộ nhãn giả phục vụ cho quá trình huấn luyện mở rộng.

Pipeline xử lý dữ liệu của mô hình thầy cũng được tái sử dụng để tạo ra phiên bản dữ liệu pseudo tương thích, nhằm bảo đảm sự thống nhất giữa các thành phần dữ liệu khi đưa vào mô hình. Từ đó, tập pseudo gồm $(X_{\text{pseudo}}, y_{\text{pseudo}})$ được kết hợp với dữ liệu train và original để hình thành bộ dữ liệu mở rộng, phục vụ huấn luyện hai pipeline bổ sung là p3 và p4.

Với mỗi pipeline pseudo, mô hình AutoGluon được huấn luyện lại từ đầu trên bộ dữ liệu mới này. Sau khi huấn luyện, hệ thống tiếp tục tính toán OOF, xác định ngưỡng phân loại tối ưu và lưu lại các dự đoán cuối cùng trên tập test. Quy trình này giúp mô hình khai thác thêm thông tin từ tập test dưới dạng nhãn giả, qua đó tăng kích thước tập huấn luyện và cải thiện khả năng tổng quát hoá của toàn bộ hệ thống.

5.5 Stacking

Đầu tiên, thu thập tất cả các dự đoán OOF và dự đoán trên tập test từ mọi mô hình base đã huấn luyện. Đối với hai mô hình AutoGluon đã huấn luyện trên dữ liệu pseudo (ag_pseudo_p3 và ag_pseudo_p4), chỉ lấy phần

dự đoán OOF tương ứng với chiều dài của tập train gốc để đảm bảo tính đồng bộ.

Tiếp theo, hệ thống xây dựng hai ma trận đặc trưng ở mức meta. Ma trận OOF bao gồm các cột là vector xác suất OOF của từng mô hình base (kích thước: số mẫu train $\times$ số mô hình), trong khi ma trận test chứa các dự đoán xác suất trên tập test theo cùng thứ tự cột.

Dựa trên hai ma trận này, hệ thống huấn luyện hai meta-model độc lập: Logistic Regression (sử dụng `cross_val_predict` để thu được OOF-probability) và Ridge (lấy OOF dự đoán dạng liên tục). Sau khi thu được dự đoán OOF và test ở tầng meta, cả hai mô hình được fit lại trên toàn bộ ma trận OOF để tạo ra dự đoán cuối cùng trên tập test.

Để kết hợp hai meta-model này, hệ thống thực hiện bước blending bằng cách sử dụng Optuna để tối ưu hai trọng số không âm (w_{lr}, w_{ridge}), được chuẩn hoá sao cho tổng bằng 1, cùng với một threshold. Tại mỗi trial, Optuna tạo vector OOF hợp nhất bằng cách nhân ma trận meta với vector trọng số, áp threshold để sinh nhãn nhị phân, và trả về accuracy trên tập train. Optuna sẽ tìm bộ trọng số và threshold mang lại accuracy cao nhất.

Sau khi tối ưu, trọng số tốt nhất được chuẩn hoá và sử dụng để kết hợp cả ma trận OOF và ma trận test nhằm tạo ra dự đoán cuối cùng. Hệ thống sau đó lưu lại submission với threshold tối ưu tìm được. Quy trình stacking và blending này giúp tận dụng ưu điểm của từng meta-model (Logistic Regression phù hợp mô tả quan hệ logit trong khi Ridge cho dự đoán liên tục ổn định), từ đó tạo ra mô hình tổng hợp có khả năng tổng quát hoá tốt hơn so với việc sử dụng từng mô hình riêng lẻ.

6. Thử nghiệm và kết quả

6.1 Thiết lập thí nghiệm

Các thí nghiệm được thực hiện trên môi trường Kaggle Notebook, với cấu hình cụ thể như sau:

- Ngôn ngữ: Python 3.11
- Môi trường thực thi: CPU
- Các thư viện chính:
 - scikit-learn: các mô hình cơ bản và metric đánh giá
 - AutoGluon Tabular: AutoML ensemble
 - LightGBM / XGBoost / CatBoost: các mô hình boosting
 - Optuna: tối ưu siêu tham số và tối ưu threshold
 - pandas, numpy: xử lý dữ liệu

6.2 Các tiêu chí đánh giá

Bài toán phân loại nhị phân được đánh giá chính trên chỉ số Accuracy theo yêu cầu cuộc thi, ngoài ra bài toán còn áp dụng một số chỉ số khác để đánh giá mô hình, cụ thể:

Table 3: Các tiêu chí đánh giá mô hình

Metric	Ý nghĩa	Lý do chọn
Accuracy	Tỷ lệ mẫu được dự đoán đúng trên toàn bộ dữ liệu.	Đánh giá hiệu suất tổng quan của mô hình và dùng để so sánh giữa các nhóm mô hình.
Precision (Lớp 1)	Trong số các mẫu được dự đoán là trầm cảm, tỷ lệ mẫu thực sự trầm cảm.	Tránh gán nhầm trạng thái trầm cảm cho người không mắc, hạn chế gây tác động tâm lý không cần thiết.
Recall (Lớp 1)	Trong số các mẫu thực sự trầm cảm, tỷ lệ mô hình dự đoán đúng là trầm cảm.	Quan trọng nhất trong bài toán sức khỏe tinh thần: giảm thiểu nguy cơ bỏ sót người có trầm cảm (False Negative).
F1-Score (Lớp 1)	Trung bình điều hòa giữa Precision và Recall.	Đảm bảo mô hình cân bằng giữa dự đoán đúng và phát hiện đúng trong bối cảnh dữ liệu có thể mất cân bằng lớp.

6.3 Kết quả huấn luyện và đánh giá mô hình




Figure 15: Biểu đồ accuracy trung bình của các models.

So sánh tổng thể các mô hình.

Biểu đồ Average Accuracy cho thấy hiệu suất trung bình của toàn bộ các mô hình base, mô hình pseudo-label và meta-model.

- Stacked_LR_Ridge đạt accuracy cao nhất: 0.941301.
- Các mô hình tiếp theo có kết quả cao: ag_pseudo_p4, ag_p2, ag_p1, goss_p2.
- Logistic Regression (lr_p1, lr_p2) đạt kết quả thấp nhất (≈ 0.818).

Nhóm mô hình boosting và AutoGluon cho hiệu suất ổn định nhất, trong khi tầng stacking tiếp tục cải thiện và trở thành mô hình tốt nhất.

Hiệu suất mô hình Stacking.

Sau tối ưu hoá bằng Optuna, tầng meta đạt:

- Accuracy: 0.9413
- Trọng số: Ridge = 0.99766, LR = 0.00234
- Ngưỡng phân loại: 0.5060

Classification Report:

Table 4: Kết quả đánh giá mô hình phân loại

Lớp	Precision	Recall	F1-score
Lớp 0	0.9599	0.9687	0.9643
Lớp 1	0.8529	0.8178	0.8350

Accuracy: 0.9413

Nhận xét:

- Độ chính xác tổng thể (accuracy = 0.9413) rất cao, cho thấy mô hình phân loại tốt trên toàn bộ tập dữ liệu.

- Lớp 0 có precision = 0.9599 và recall = 0.9687, chứng tỏ mô hình nhận diện đúng hầu hết các mẫu Negative và bỏ sót rất ít.
- Lớp 1 có kết quả thấp hơn (precision = 0.8529, recall = 0.8178) nhưng vẫn ở mức tốt.

6.4 Phân tích chi tiết.

- Tầng meta kết hợp hơn 15 mô hình base, bao gồm các thuật toán boosting, AutoGluon và mô hình pseudo-label.

- Các mô hình boosting và AutoML thường có phương sai cao; stacking giúp giảm phương sai của dự đoán làm mô hình ổn định hơn.
- XGBoost xử lý tốt quan hệ phi tuyến, LightGBM tối ưu tốc độ, CatBoost mạnh với categorical, AutoGluon mạnh về ensemble tự động. Meta-model kết hợp các đặc tính này tạo ra tín hiệu tổng hợp chất lượng hơn.
- Quy trình blending tìm kiếm trọng số tối ưu dựa trên OOF, đồng thời tối ưu threshold giúp cải thiện accuracy đáng kể.

- Nhóm mô hình ag_p2, ag_p1, ag_pseudo_p4 nằm trong top mô hình tốt nhất nhờ:

- AutoGluon chạy song song nhiều mô hình như GBM, RF, NN, kNN, ExtraTrees mà không cần can thiệp thủ công.
- AutoGluon tự xây dựng weighted ensemble từ các mô hình con, giúp cải thiện hiệu suất đáng kể.
- Các hyperparameters quan trọng được tinh chỉnh tự động dựa trên hiệu suất validation.
- Đặc biệt, mô hình ag_pseudo_p4 cho thấy hiệu quả rõ rệt khi kết hợp với pseudo-label, chứng tỏ AutoGluon tận dụng tốt thông tin mở rộng từ test set.

- Các mô hình boosting như LightGBM, XGBoost, GOSS và DART đều đạt accuracy khoảng 0.939–0.940, thể hiện mức độ ổn định cao.

- Tree-based boosting phù hợp với dữ liệu có nhiều biến categorical và tương tác phức tạp.
- Boosting là nhóm mô hình được sử dụng rộng rãi nhất cho dạng dữ liệu này.
- Kết quả đồng đều giữa các pipeline (p1 và p2) cho thấy các mô hình boosting ít bị ảnh hưởng bởi thay đổi tiền xử lý.

- Hai mô hình lr_p1 và lr_p2 đạt accuracy thấp nhất. Nguyên nhân:

- Logistic Regression là mô hình tuyến tính, trong khi bài toán chứa nhiều quan hệ phức tạp.
- Dù đã one-hot encoding, nhưng số lượng category lớn làm mô hình khó học hiệu quả.
- Không giống boosting hay AutoGluon, Logistic Regression không thể học quan hệ phi tuyến hoặc các tương tác bậc cao.

Kết quả này cho thấy các mô hình phi tuyến như boosting, AutoML hoặc stacking phù hợp hơn với bài toán dự đoán trạng thái tâm lý.

6.5 Kết quả nộp trên Kaggle

Sau khi tối ưu mô hình trên tập validation, nhóm tiến hành tạo submission và nộp lên cuộc thi Kaggle.




Figure 16: Kết quả nộp trên Kaggle

Bảng so sánh hiệu suất mô hình

Table 5: So sánh hiệu suất mô hình giữa Offline và Kaggle Public/Private Leaderboard

Metric	Offline (Validation)	Public LB	Private LB
Accuracy	0.9413	0.94339	0.94165

Nhận xét:

- Sai lệch chỉ khoảng $\pm 0.002 \rightarrow$ mô hình rất ổn định.
- Public Score cao hơn Validation $\rightarrow$ có thể mô hình học được tốt các đặc trưng tổng quát.
- Private Score gần bằng Offline $\rightarrow$ chứng minh không overfit vào tập Public LB.

7. Kết luận và cải tiến

7.1 Kết luận

Trong báo cáo này, nhóm đã xây dựng một hệ thống dự đoán trạng thái tâm lý kết hợp nhiều mô hình học máy hiện đại, các pipeline xử lý dữ liệu khác nhau, kỹ thuật pseudo-labeling và phương pháp stacking ở tầng meta. Kết quả thực nghiệm cho thấy:

- Các mô hình boosting (LightGBM, XGBoost, GOSS, DART) và AutoGluon đều đạt hiệu suất cao và ổn định, phản ánh khả năng mô hình hoá tốt các quan hệ phi tuyến trong dữ liệu.
- Kỹ thuật pseudo-labeling giúp mở rộng dữ liệu huấn luyện và cải thiện độ chính xác của một số mô hình, đặc biệt là khi kết hợp với AutoGluon.
- Tầng meta-model sử dụng blending giữa Ridge và Logistic Regression, tối ưu hoá bằng Optuna, đạt accuracy OOF cao nhất 0.9411, vượt qua toàn bộ mô hình base và giả lập. Điều này cho thấy stacking mang lại lợi ích rõ rệt khi tổng hợp tín hiệu từ nhiều mô hình khác nhau.
- Những mô hình tuyến tính như Logistic Regression hoạt động kém hiệu quả hơn, cho thấy bài toán có tính phi tuyến mạnh và đòi hỏi các phương pháp mô hình hoá linh hoạt hơn.

Tổng thể, hệ thống đề xuất đã chứng minh tính hiệu quả vượt trội nhờ sự kết hợp giữa các mô hình mạnh. Kết quả đạt được khẳng định rằng cách tiếp cận đa mô hình và meta-learning là lựa chọn phù hợp cho các bài toán dự đoán hành vi hoặc trạng thái tâm lý dựa trên dữ liệu thực tế.

7.2 Cải tiến

Thay vì sử dụng Logistic Regression và Ridge làm meta-model, một hướng cải tiến trong tương lai là thay thế tầng meta bằng AutoGluon. AutoGluon có thể được huấn luyện trực tiếp trên ma trận OOF (và ma trận dự đoán test tương ứng), với tùy chọn `presets='best_quality'`, tăng thời gian huấn luyện (9 - 10 tiếng) và cấp nhiều tài nguyên. Ở chế độ này, AutoGluon tự động tìm kiếm mô hình tốt nhất và thực hiện ensemble nâng cao, thường giúp cải thiện hiệu suất so với meta-model tuyến tính truyền thống.

Lợi ích chính:

- Tự động thử nghiệm nhiều thuật toán khác nhau (GBM, Neural Networks, Random Forest,...) và kết hợp chúng trong một mô hình ensemble cuối.
- Tự tối ưu hyperparameters và trọng số ensemble mà không cần tinh chỉnh thủ công.
- Có khả năng cải thiện đáng kể hiệu suất OOF và trên tập test nhờ khả năng học mô hình phi tuyến mạnh mẽ hơn.

7.3 Video thuyết trình

Bài thuyết trình của nhóm được đăng tải công khai trên YouTube tại đường dẫn sau: [Youtube](#)

Nguồn tham khảo

- [1] Mahdi Ravaghi. *1st Place Solution - Playground Series S4E11*. <https://www.kaggle.com/competitions/playground-series-s4e11/writeups/mahdi-ravaghi-1st-place-solution>. Truy cập: 2025-11-27. 2024.